Actividad Práctica 01

Fundamentos de Databricks — Blur Consulting

Estudiante: Isabela Tellez

Fecha: 23 de octubre de 2026

1. Objetivo

Completar tres retos sobre la arquitectura Medallion en Databricks: crear una tabla Gold con las películas de mayor retorno, añadir una regla de calidad en Silver y documentar, etiquetar y conceder permisos a la nueva tabla.

2. Reto 1: tabla Gold de películas rentables

Se creó workspace.cine_gold.peliculas_rentables a partir de workspace.cine_silver.peliculas. El retorno se calcula con try_divide(recaudacion_mundial, presupuesto), se exige votos_imdb > 10000, se ordena el resultado por retorno descendente y se limita a 50 filas.

Consulta ejecutada:

```
CREATE OR REPLACE TABLE workspace.cine_gold.peliculas_rentables
COMMENT 'Las 50 películas con mayor retorno taquilla mundial/presupuesto entre títulos con más de 10000 votos en IMDb'
AS
SELECT titulo, fecha_estreno, genero, director, presupuesto,
    recaudacion_mundial, votos_imdb, calificacion_imdb,
    try_divide(recaudacion_mundial, presupuesto) AS retorno
FROM workspace.cine_silver.peliculas
WHERE votos_imdb > 10000
 AND presupuesto > 0
 AND recaudacion_mundial IS NOT NULL
ORDER BY retorno DESC
LIMIT 50;
```

Resultado obtenido: [Completar tras ejecutar la consulta en Databricks. La tabla debería contener hasta 50 filas.]

3. Reto 2: nueva regla de calidad

Se modificó la vista temporal peliculas_evaluadas para añadir el motivo de rechazo “sin género ni director” cuando genero IS NULL AND director IS NULL. Después se reconstruyó la tabla de cuarentena y se comparó su número de filas antes y después de aplicar la regla.

Regla añadida:

```
CASE WHEN genero IS NULL AND director IS NULL
    THEN 'sin género ni director' END
```

Consulta para cuantificar el cambio:

```
SELECT
   antes.filas_antes,
   despues.filas_despues,
   despues.filas_despues - antes.filas_antes AS filas_adicionales_cuarentena
FROM cuarentena_antes antes
CROSS JOIN (
   SELECT COUNT(*) AS filas_despues
   FROM workspace.cine_silver.peliculas_cuarentena
) despues;
```

Resultado obtenido: filas antes = [completar]; filas después = [completar]; filas adicionales en cuarentena = [completar].

Tras el cambio también se reconstruyó workspace.cine_silver.peliculas para que la tabla Silver válida reflejara la regla actualizada. Si el entorno exige las restricciones del apartado 6 del notebook, deben reaplicarse después de recrear la tabla.

4. Reto 3: documentación, etiquetas y permisos

Se documentó la tabla con COMMENT, se añadieron etiquetas mediante SET TAGS y se concedió acceso de lectura mediante GRANT.

Comentario de tabla:

```
COMMENT ON TABLE workspace.cine_gold.peliculas_rentables IS
'Top 50 de películas con mayor retorno de taquilla mundial sobre presupuesto,
considerando únicamente películas con más de 10000 votos en IMDb.';
```

Etiquetas:

```
ALTER TABLE workspace.cine_gold.peliculas_rentables
SET TAGS (
   'capa' = 'gold',
   'dominio' = 'cine',
   'uso' = 'analitica',
   'criterio' = 'retorno_peliculas'
);
```

Permisos:

```
GRANT USE SCHEMA
ON SCHEMA workspace.cine_gold
TO `account users`;

GRANT SELECT
ON TABLE workspace.cine_gold.peliculas_rentables
TO `account users`;
```

Nota: confirmar que `account users` es el principal adecuado para el workspace; sustituirlo si el material del curso indica otro grupo o usuario.

5. Conclusiones

La actividad amplía la capa Gold con una tabla enfocada en rentabilidad, refuerza la calidad de Silver mediante una nueva regla explícita y aplica prácticas de gobierno con documentación, etiquetas y permisos. Los resultados cuantitativos deben completarse con las salidas reales del notebook ejecutado en Databricks.

6. Lista de comprobación antes de entregar

- Ejecutar las celdas nuevas en orden y comprobar que finalizan sin errores.
- Verificar que peliculas_rentables contiene las columnas y el orden esperado.
- Anotar el recuento de cuarentena antes y después, así como las filas adicionales.
- Confirmar que los permisos se concedieron al principal correcto.
- Revisar las salidas y guardar el notebook .ipynb actualizado.

- Sustituir los campos [completar] por resultados reales.